

ERNIE-Image 昇腾 910A 单卡部署镜像说明

下载信息

项目	详情
镜像下载链接	http://119.6.186.130:12080/ernie-image-ascend910a-deploy-package_20260421.tar.gz
镜像大小	716 MB (压缩后)
SHA256	fa1704bd2241ed4a152724528c76eea0e5984fcf6d96dd57adceb522204c40e5
下载有效期	临时服务，建议尽快下载

快速部署步骤

1. 下载部署包

```
wget http://119.6.186.130:12080/ernie-image-ascend910a-deploy-package_20260421.tar.gz
```

2. 解压

```
tar -xzf ernie-image-ascend910a-deploy-package_20260421.tar.gz
```

3. 导入镜像

```
docker load < ernie-image-ascend910a-single_20260421.tar.gz
```

4. 准备模型权重

从 ModelScope 下载 ERNIE-Image 模型到 [/path/to/model](#):

```
mkdir -p /path/to/model/PaddlePaddle
cd /path/to/model/PaddlePaddle
# 使用 modelscope snapshot_download 下载 ERNIE-Image
# 目录结构: /path/to/model/PaddlePaddle/ERNIE-Image/
```

5. 启动服务

```
docker run -d \
--name ernie-image-single \
--device /dev/davinci0:/dev/davinci0 \
--device /dev/davinci_manager:/dev/davinci_manager \
--device /dev/devmm_svm:/dev/devmm_svm \
--device /dev/hisi_hdc:/dev/hisi_hdc \
-v /usr/local/Ascend:/usr/local/Ascend:ro \
-v /etc/ascend_install.info:/etc/ascend_install.info:ro \
-v /path/to/model:/root/ernie_image_deploy/model:ro \
-v /path/to/outputs:/data/outputs \
-p 12050:8080 \
-e ERNIE_IMAGE_MODEL_DIR=/root/ernie_image_deploy/model/PaddlePaddle/ERNIE-Image \
-e ASCEND_RT_VISIBLE_DEVICES=0 \
ernie-image-ascend910a:20260421
```

6. 验证服务

```
# 健康检查
curl http://localhost:12050/health

# 测试生成
curl -X POST http://localhost:12050/generate \
-H 'Content-Type: application/json' \
-d '{"prompt": "a beautiful sunset", "steps": 4, "height": 512, "width": 512}'
```

性能预期

指标	数值
首次推理 (含算子编译)	~220 秒
后续推理	~32 秒
分辨率	512x512
推理步数	4 steps
显存占用	~32GB

镜像内置优化

- VAE Slicing: 解决 32GB 显存下的 OOM 问题
- torch_npu NPU 加速: 腾 910A 原生支持
- CANN 算子自动融合: 30~50% 性能提升
- PyTorch 3.10 环境: 完整的 Python 运行时

环境变量配置

变量名	说明	默认值
ERNIE_IMAGE_MODEL_DIR	模型目录路径	/root/ernie_image_deploy/model/PaddlePaddle/ERNIE-Image

变量名	说明	默认值
ERNIE_IMAGE_OUTPUT_DIR	输出目录	/data/outputs
ASCEND_RT_VISIBLE_DEVICES	NPU 设备编号	0
ERNIE_IMAGE_DTYPE	精度	float16

前置要求

- 腾 910A 服务器 (单卡 32GB 显存以上)
- openEuler 22.03 LTS 或兼容系统
- CANN 7.0+ Toolkit 已安装在 [/usr/local/Ascend](#)
- Docker 18.09+

注意事项

1. 临时下载服务会在服务器重启后停止，请尽快下载
2. 镜像不包含模型权重，需单独从 ModelScope 下载
3. 首次推理包含算子编译过程，耗时较长属于正常现象
4. 完整部署说明详见部署包内的 [README_DEPLOY.md](#)